JIT：面向跳跃策略能力扩展的可学习探索与生成式恢复指导

中文论文工作稿 · 2026 年 10 月 11 日

作者：_____ 单位：_____ 拟投稿期刊／会议：_____

阅读说明：本文按“可学习探索 E—恢复教师 G—跳跃策略 π”的完整研究思路撰写。已有实验按原始证据填入；黄色“【待补 P 编号】”为尚缺的论文证据，不代表已得到相应结论。本文目前是供修改的研究草稿。正文中的开发集、确定性复核和独立训练种子严格区分。文末附证据索引和待补结果清单。

摘要

机器人跳跃策略在固定起点和常见扰动下取得成功，并不意味着其已经掌握偏离训练分布后的恢复行为。直接增加扰动强度可能产生大量当前策略无法处理、也难以转化为学习信号的状态。为此，本文研究一种由可学习探索、生成式恢复教师和跳跃策略学习组成的迭代框架 JIT。探索器在冻结跳跃策略的动作上施加有界短时扰动，产生真实动力学可达的状态；条件扩散模型从扰动后状态生成短动作序列，经模拟器验证并交回冻结策略完成任务，形成带来源的恢复示范；学生策略利用合格示范与旧技能保持数据更新，并以独立闭环成功、新增能力和旧能力损失评价学习效果。框架进一步将策略学习进展反馈给后续探索与教师更新。

本文报告固定方法契约下的阶段性开发证据。对 160 个新采集初态筛查后，选取 16 个 TRAIN 与 7 个 SOL VER_DEV 稳定失败根进行同状态教师比较：生成教师与有色噪声教师在固定赢家重复验证资格上呈互补，生成教师形成 8 条合格 TRAIN 教案。在 8 个学生训练根的 24 个自身访问状态查询中，12 个查询满足源策略三次失败、固定生成教师三次成功；其中 4 条指导来自 3 个历史稳定失败祖先。新增自身访问指导后，学生三次复核的稳定吸收仍为 4/8；一个失败根被修复，同时一个原成功根丢失。完整开发集首次评测为 56/64，相对原 π_0 新增 20 例、丢失 2 例，但该配对改善尚缺重复确认。本文据此支持“有限状态上存在可验证恢复指导”及“指导到学生的转化可被分解测量”，尚不支持扩散必要性、可靠无遗忘或最终单策略泛化优势。多种子等成本比较与统一口径迁移评价保留为明确待补实验。

关键词： 机器人跳跃；可学习探索；条件扩散；恢复指导；策略蒸馏；能力保持

1 引言

跳跃控制要求机器人协调轮系与关节驱动，并在离地、腾空、接触和落地后恢复之间完成状态转换。训练得到的名义策略通常只覆盖有限的状态分布：在常见初态上能够跳跃，不保证执行器扰动或接触误差使轨迹发生偏移后仍能完成任务。本文关注如何利用已经具备跳跃能力的策略，逐步发现其尚未掌握但存在恢复方案的状态，并将这些恢复行为转化为同一部署策略的能力。

这一问题存在三个相互联系但不能混淆的环节。第一，探索需要产生有学习价值的状态，而非仅获得更远、更偏或更容易失败的轨迹。第二，当前策略失败不等于该状态不存在可行恢复动作，恢复教师需要

提供真实执行后可以完成任务的指导。第三，教师成功不能直接计入学生成绩：学生必须在没有教师介入的情况下独立成功，同时记录是否失去了原有能力。

基于这一划分，JIT 将探索器 E、生成教师 G 和跳跃策略 π 分开建模。E 负责改变状态分布，G 负责将部分失败状态转化为带验证标签的恢复示范，π 负责把这些示范吸收到闭环控制中。部署目标为独立跳跃策略；教师候选搜索发生在训练侧。旧策略既是教师短桥接后的尾部控制器，也是能力保持的参照。最终评价仍从声明的完整起点进行，不能以中间快照恢复或教师辅助结果替代完整任务表现。

本文的工作包括：建立 E—G—π 及学习进展反馈的统一方法表述；实现恢复示范的来源、尾部策略、交接时序和固定赢家复核；给出教师可解性、学生吸收、旧能力损失及自身状态诊断的分解证据。当前稿件不将“实现了模块”写成“证明了该模块必要”。【待补 P1—P4】完整框架相对等成本基线的优势，将由第 6.6 节预留的主实验与消融结果支撑。

2 相关工作

动态技能与跳跃学习。 自行车机器人动态技能已有强化学习研究。Bicycle Acrobatics 展示了多种特技及策略组织；LineRides 研究了空间引导线下的特技学习。[1,2] 因而本文不以“首次实现自行车跳跃”为贡献，研究重点是既有跳跃策略的恢复能力扩展及其证据链。

残差探索与课程学习。 残差强化学习通过组合基础控制与学习信号利用已有控制能力。[3] PPO 提供了可用于策略更新的优化方法。[4] 新颖性驱动探索和自动课程分别从访问分布和学习难度组织经验。[5,6] JIT 借鉴这些思想，但探索奖励产生了新状态，仅说明访问分布发生改变；这些状态是否可恢复、是否可被学生掌握，仍需后续实验验证。

扩散动作模型与恢复示范。 去噪扩散模型通过逐步去噪学习数据分布，Diffusion Policy 将条件扩散用于机器人动作序列建模。[7,8] JIT 使用条件扩散生成有限时域恢复动作，并通过物理执行与冻结策略接续筛选示范。本文不将扩散直接作为部署控制器，也不由建模形式推断其优于更简单的动作搜索。相同候选数的生成教师与有色噪声对照，以及最终学生的等总成本比较，需要分别报告。

闭环模仿与能力保持。 DAgger 指出，策略自身诱导的状态分布与教师示范分布可能不同。[9] 这一问题为查询学生自身访问状态提供了方法动机，但不能直接证明本任务的误差原因。本文将“老师在学生状态可救”“学生能拟合指导”和“独立学生闭环改善”分开检查，并用逐题新增／丢失计数描述能力变化。本文的有限示范补充不声称满足 DAgger 理论的全部前提，也不提供无遗忘保证。

3 问题定义与评价语义

3.1 任务、完整上下文与策略

设完整仿真与控制上下文为 χ，包含物理位置与速度、观测历史、上一动作、执行器状态、事件历史、阶段标记、随机数状态以及任务时钟。Actor 仅使用其声明观测 o，特权信息不直接作为部署 Actor 输入。将离散控制系统抽象为：

$$\chi_{t+1} = F(\chi_t, \mathrm{Map}(a_t)), \quad o_t = O(\chi_t), \quad a_t \in [-1,1]^4。 \qquad (1)$$

当前保持性实验每 20 ms 施加一次动作，物理步长 5 ms。四个归一化动作通道按顺序为转向、后轮驱动、髋关节和膝关节；执行器位置／速度目标映射、范围及关键帧中心的绝对关节目标语义与 checkpoint 共同

冻结。恢复指导改变控制动作，不直接生成或篡改物理状态。完整上下文恢复保留声明字段，但不等价于模拟器所有内部接触缓存的逐位恢复。

本文使用 $S(\pi,\chi)$表示策略在给定初始上下文下是否满足冻结成功判据。近期 retention 实验的成功要求有效落地后连续 25 个控制步保持稳定，包括前向速度不低于 0.5 m/s、侧倾绝对值不超过 10°、俯仰绝对值不超过 15°、轮间隙／穿透和机身接触条件合格；并排除同时发生的物理失败与超时。[E8] 这一定义不同于仅记录首次落地，也不同于第 6.5 节 sim2sim 所用的 1 s 稳定窗口。

3.2 新能力、保持性与教师辅助能力

在同一评价条件集合 I 上，记原策略与学生的成功标签分别为 $y^0{}_i$ 和 $y^s{}_i$。定义新增成功 G、旧成功丢失 L 和净差 Δ：

$$G = \Sigma_i\, 1[y^0{}_i=0 \wedge y^s{}_i=1],\quad L = \Sigma_i\, 1[y^0{}_i=1 \wedge y^s{}_i=0],\quad \Delta = G - L\ 。 \qquad (2)$$

成功总数增加允许 G 与 L 同时非零。因此，总成功率、净差和保持率需要同时说明，不能互相替代。若旧策略成功样本数为 N_0，条件保持率为$(N_0-L)/N_0$。未知或缺失标签另列，不计入有效二元配对；$N_0=0$ 时保持率记 NA。这里的标签依赖声明的数值布局和重复协议；重复标签翻转单列为歧义，不能全部归因为真实遗忘。

教师系统 T 由短动作桥接与冻结 π 尾部共同组成。只有原策略失败、T 通过物理复核的状态，才构成相对该原策略的增量指导。学生能力仍用 $S(\pi^s,\chi)$单独计算。某个历史学生曾经成功、当前学生失败，属于历史技能回退；当 π_0 本来就失败时，不能将其记成 π_0 旧能力损失。

3.3 数据角色与证据单位

TRAIN 可用于探索、教师拟合、学生监督和自身访问状态查询；SOLVER_DEV 用于固定恢复初态上的开发排序；完整 DEV 用于配对能力变化与保持性警戒。最终 TEST 尚未开启。多个时点来自同一祖先、同一初态的确定性复核、同一训练 checkpoint 下的大量环境回合，均不等于独立训练种子。文中所有成功数同时注明分母和数据角色。

4 JIT 方法

4.1 总体框架与冻结关系

图 1 使用作者提供的原始框图。每轮先冻结当前跳跃策略 π_k，探索器 E_k 产生真实扰动后状态；恢复教师 G_k 提出短动作序列，经物理执行后交回 π_k 完成任务；合格数据用于训练候选学生 π_{k+1}。更新后的策略能力与学习进展形成下一轮反馈。图中的“Skill expansion”和“Robust generalization”表示研究目标，不能直接作为实验证明。

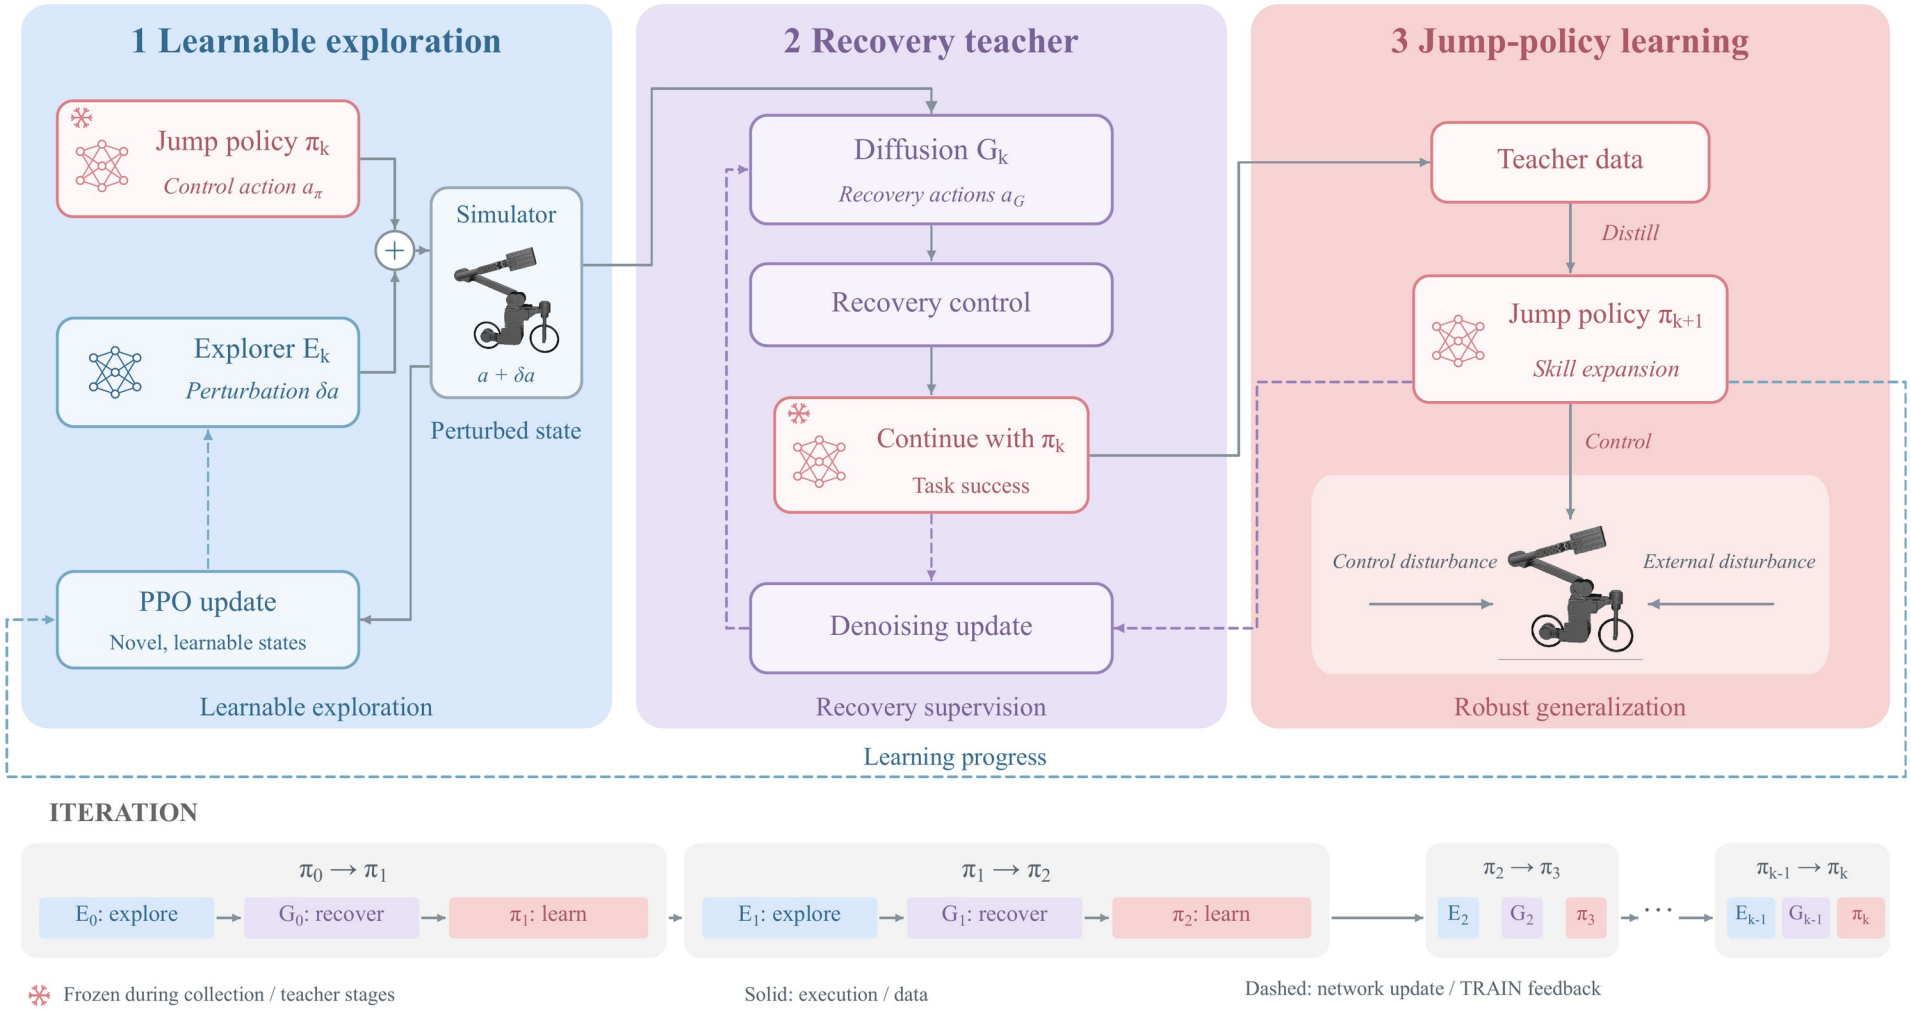


图 1. JIT 总体方法框图。 原图来自作者提供的 JIT-core-method-network-icons.pdf，内容未修改。实线为执行／数据通路，虚线为网络更新／TRAIN 反馈，雪花标记表示相应采集与教师阶段冻结。文中的教师验证和学生保持检查是这些通路的执行与评价约束。对反馈、能力扩展及泛化的有效性证据见第 6 节；框图本身不是有效性结果。

4.2 可学习探索

第 k 轮采集时冻结 π_k，探索器根据特权状态与历史邻域证据 x，输出高斯分布的均值 $\mu^E(x)$与对角方差 $\sigma^{E2}(x)$；采样潜在动作 z 后经 tanh 变换得到有界扰动。令 m_t 表示本回合唯一的三步扰动窗口，则实际执行动作为：

$$\delta a_t = 0.25\tanh(z_t),\qquad a_t = \mathrm{clip}(\pi_k(o_t)+m_t\delta a_t,-1,1)。\qquad (3)$$

这里 $\pi_k(o)$指归一化确定性动作；记录请求扰动和裁剪后的实际扰动。当前连续协议按 0、5、10、15 四个控制步起点调度窗口，其余时刻由冻结跳跃策略控制。探索发生在控制动作空间，不改变质量、摩擦或成功判据。

R73 实际使用邻域探索器：原始输入 386 维，由 106 维特权状态、16×17 邻域条目及 8 个统计量组成。邻域条目经编码与掩码平均形成 64 维摘要，再与状态／统计拼接为 178 维，输入三层 128 单元 ELU Actor 和独立 Critic。邻域证据区分当前源策略成功／失败、历史策略成功和历史已验证教师成功；在本批采集前冻结，不读取本轮尚未得到的学习结果。[E9]

探索 PPO 使用本轮新行为、潜在动作、行为概率与同根延迟反馈，γ=λ=1；当前声明 4 个优化 epoch、概率比 clip=0.2、目标 KL=0.01。未执行动作、填充和未知标签不参与更新。当前 learned-only 协议 uniform_episode_fraction=0；D1 的噪声教师是独立对照，不应误画成当前 E 采集内的一条 20%随机分支。

网络接口（已核对 R73 执行配置）

模块	主要输入	网络／输出	用途
跳跃 Actor π	76 维：3×25 真实历史＋jump_signal	256×3；tanh-normal 四维归一化动作	独立闭环控制
跳跃 Critic	106 维特权观测	256×3；标量价值	PPO 训练
探索器 E	386 维原始邻域输入→178 维头输入	128×3 ELU Actor／Critic；四维扰动	训练侧状态探索
生成教师 G	归一化 76 维条件、噪声时刻、16×4 带噪序列	1D U-Net 通道 64/128/256；同形状噪声预测	恢复动作序列生成

当前观测中名为 estimated_forward_velocity 的字段在仿真实现中使用真实根部前向速度；从仿真走向实际部署时，其测量／估计接口仍需验证，不能仅凭字段名称称完全可部署。

4.3 条件扩散恢复教师

以完整快照对应的 76 维 Actor 观测作为条件，生成教师输出 H×4 归一化动作序列 U。本稿涉及的标准桥接窗口 H=16，即 0.32 s。条件扩散训练对成功动作序列加噪，并学习噪声预测：

$$U_r = \sqrt{\bar\alpha_r}\,U + \sqrt{(1-\bar\alpha_r)}\,\varepsilon,\qquad L^G = E[\|\varepsilon - \varepsilon\psi(U_r,r,\bar o)\|^2/64]。\qquad (4)$$

式(4)中 ψ 为 G 参数，$\bar o$ 为该 G 所绑定固定 normalizer 归一化后的观测；学生参数另记为 θ。该式表述教师的去噪拟合目标，不能用该目标的下降代替恢复成功率。推理采用条件一维 U-Net、100 级余弦噪声日程、20 步 DDIM 与 EMA 参数。R73 保留 last_valid 完整状态，G-DEV 去噪误差仅用于监测，不据此选本组评价最优模型。当前有限教师比较固定已完成 G73，既不更新 G，也不根据这组评价选择新的生成器。

教师从同一快照生成 16 个候选，并加入 1 条不执行生成前缀的冻结尾部 π_k 源策略分支（近期 D1／自身访问诊断固定为 π_0），形成 17 世界完整布局。候选仅执行声明桥接窗口，然后不重置物理状态地切回冻结尾部策略，直至成功、失败或任务时限。近期 D1／自身访问诊断先按固定规则选定赢家，再做两次相同布局复核；连续 R73 主线为搜索后一次复核，二者分别记录。不在复核后重新选一个恰好成功的候选。近期 D1 将独立 π_0 三次失败、源分支三次失败和固定赢家三次成功同时作为增量教案准入条件。在完整成功候选中，按全轨迹动作变化平方和最小、任务回报最大、候选编号最小的字典序固定赢家；动作变化从根的真实上一动作起算。

标准桥接可表示为式(5)，其中ℓ从本次查询根起算，t_0 为根对应的任务控制时刻；局部桥接计数与原任务时钟分别保留：

$$a_\tau(t_0+\ell) = U_\ell \ (0\le\ell<H)\ ; \quad a_\tau(t_0+\ell) = \pi_k(o(t_0+\ell)) \ (\ell\ge H)。 \qquad (5)$$

搜索与复核均保留失败候选。完整评价中未找到成功，仅表示当前教师、窗口与搜索预算未找到见证；未完成、非有限、工程错误或标签冲突不能改写为“物理无解”。实际费用同时包括成功、失败、填充和固定复核。

4.4 跳跃策略学习与旧技能保持

完整连续主线使用 PPO 任务学习与示范／保持辅助项共同优化学生：

$$L^s = L^{PPO} + \lambda^D(u)L_{demo} + \lambda^K L_{keep}。 \qquad (6)$$

已执行 R73 每轮使用 128,000 条新的 PPO 转移；λ^D 从 0.2 降至 0.05，λ^K=0.2，两类辅助样本每批各 256。学生 PPO 使用学习率 3×10^{-5}、clip=0.1、γ=0.995、GAE λ=0.97、全梯度上界 0.75、128 环境与 unroll25。该主线中运行归一化统计会更新，退火按本轮统计计数增量计算；不能将后述纯 BC 阶段冻结统计的契约追溯到所有历史主线。

学生训练重置混合 20%完整起跳起点与 80%快照支持，快照内部 pending 比例 0.5。完整起点训练脉冲为前三步，幅值 0／0.1／0.25 的混合概率 0.2／0.4／0.4；这与 E 采集的四种起扰窗口不同。连续训练传递完整 learner 状态，但仿真回合从声明支持重置，不恢复上一训练阶段末的接触状态。[E9]

近期机制试验单独检验监督学习通路，不运行新的 PPO、E 或 G 更新。它从原 π_0 及全新 Adam／随机数状态开始，冻结 normalizer 和 critic；以真实执行前观测和真实执行动作训练 Actor。示范损失与旧策略保持损失写为：

$$L^{Bc} = \lambda^D E_D[\|\pi\theta(o)-a^*\|^2/4] + \lambda^K E_K[\|\pi\theta(o)-\pi ref(o)\|^2/4]。 \qquad (7)$$

式(7)中的策略均表示包含各自身份绑定 normalizer 的 tanh-normal 确定性动作；πref 参数与统计均固定并停止梯度，本次纯 BC 的学生统计也固定。两项分别使用验证恢复示范和独立 TRAIN 旧技能数据，不在同一困难状态上盲目平均两个老师的动作。当前控制组与自身访问示范试验均取 $\lambda^D=\lambda^K=1$，两个来源每次各采样 256 帧；Actor 优化使用 Adam 10^{-5} 和全局梯度裁剪 1。该保持项只约束采样状态上的动作一致性，不保证完整闭环无遗忘。

原始 8 个示范祖先等权，每条轨迹的桥接前缀与源策略尾部各占一半质量。自身访问试验在祖先内部均衡新旧轨迹。旧 525 帧观测与动作保持原值，但采样质量由重新分配决定：新 228 帧的采样质量为 5/24，不能用 228/753 代表实际监督占比。

4.5 学生自身访问状态上的指导诊断

为诊断学生在教师已解决初态上的失败，先对预声明的全部 8 个 TRAIN 祖先运行完整学生闭环，在从原教师根起算的 j∈{4,8,12}步完成后采集真实状态；成功与失败祖先均保留，后续示范准入才限制稳定失败祖先。随后从该状态比较源策略和固定生成教师，剩余桥接时长为 H−j，原总交接时刻 H 不后移：

$$H_j = H-j,\qquad j\in\{4,8,12\},\qquad H=16。\qquad (8)$$

G 仍生成固定 16 步序列，仅执行其前 H−j 步后交回 π_0，不改变网络输出长度。已终止或未到达的查询点保留在分母中，不临时替换时点。查询保留观测历史、动作历史、事件与任务时间。只有历史重复均失败、当前完整学生也失败、源分支三次失败而固定 G 赢家三次成功的查询，才进入本轮最小新增示范。新增数据采用预先固定的第二次复核完整成功后缀，不拼入此前学生失败动作。

该诊断用于区分：源策略本身可以接续、生成教师提供增量指导、当前有限搜索未找到解、重复结果歧义。只有继续训练后独立学生闭环改善，才能支持“补充自身访问状态指导改善转化”的解释。

4.6 学习进展反馈与有限迭代

框图中的反馈已在连续系列接线并执行，而不是三个网络端到端联合反向传播。探索器反馈来自同一 TRAIN 根的“学习前源策略标签→学习后学生独立标签”。对于证据有效且参与学习的根，当前质量奖励包括前 0 后 1 且允许继续采用时+2、前 0 后 0 时−0.1；施扰期间直接物理失败时奖励−2。若源策略在复核中已成功，就取消该根的新增奖励；teacher_success_bonus=0。因此，教师成功本身不是学生学习进展。[E9]

额外新颖项按冻结源 Actor 的物理格访问记录计算。令 C_i 为本次实际扰动经过的格集合、S_k 为该源策略历史访问集合、n(c)为本批对新格的重复访问数，有新格时：

$$r^{nov}_i = (0.02/|C_i|)\ \Sigma\ (1/n(c)),\ c\in C_i\setminus S_k；\quad 无新格时\ r^{nov}_i = -0.02。\qquad (9)$$

式(9)仅适用于未直接物理失败、反馈有效且$|C_i|>0$ 的回合；直接物理失败分支的新颖项为 0、总奖励为−2，空格／未知情形按实际有效性掩码处理，不套用“无新格”的−0.02。新颖性只描述有限分辨率的访问统计，不是严格可达域。当前 E 反馈没有对完整旧能力集合施加统一回归惩罚，不能解释成自动无遗忘机制。

学生到 G 的反馈用于更新成功轨迹库。G 按历史 50%、本轮验证教师 25%、本轮获连续采用学生的独立成功 25%请求采样，空来源重新归一化；来源内再按祖先、轨迹和真实 16 步窗口采样。G 每轮最多 2000 步离线去噪更新。失败、跨重置、不足窗口或非 TRAIN 轨迹不成为有效成功示范。G 训练还要求祖先属于固定 generator_train 拆分，同一祖先的片段继承相同拆分；generator-dev 只用于声明监测，不回流去噪训练。学生示范库与 G 训练库分别维护，准入和权重不相同。[E9]

必须区分实际阶段协议：连续 R73 从快照采用 fresh-continuation，重启 episode／phase 行政计时并清零恢复计数；近期 retention／自身访问诊断显式保留快照 episode 上下文和独立物理时间。二者都不在 G→π 交接时再次重置，但不能合称历史所有实验均沿原回合时钟无缝接续。

连续系列的 adopted=true 仅表示允许将完成学生用于下一轮，其 performance_gate=false、formal_adopted=false；它不是效果验收或正式部署通过。当前框图箭头有执行记录，箭头是否带来相对对照的净收益，仍需第 6.6 节的消融。

算法 1　JIT 迭代流程（方法框架）

1. 冻结采集与教师阶段使用的当前策略、观测归一化、E 行为身份、G 及历史邻域；锁定物理配置、数据角色与本轮预算。

2. 用声明的探索器及有界动作扰动采集真实前缀，保存完整扰动后上下文。

3. 从同一状态比较源策略与恢复提案；固定赢家并复核，保存全部结果与实际费用。

4. 将合格 TRAIN 恢复示范加入教师／学生训练数据，保持 DEV 与 TEST 不回流。

5. 更新候选学生；分别测量独立恢复、新增成功、旧成功丢失及历史技能回退。

6. 在声明的连续阶段，以同根学生学习前后标签更新 E 的 PPO；按角色、祖先及合法窗口组织成功轨迹，更新 G 的去噪模型。

7. 按冻结的开发规则处理候选与学习进展，再冻结下一轮所用模型；只有后续阶段被明确声明时才继续下一轮。

算法描述完整框架。第 6 节的有限诊断只执行其中被声明的子阶段，不因图中有迭代箭头就将停止的历史谱系视为连续完成。

5 实验设置

5.1 策略身份、成功标准与数据划分

本稿近期 retention 实验的 π_0 为 Phase U 训练 transition_4988928 的零更新绑定，Actor 摘要为 a06acbc8…，normalizer 摘要为 db84aad7…；G 为 R73 已完成状态的 EMA，R5 作为冻结历史开发候选。保存的 Actor、normalizer 和来源必须共同对应，不只按文件名比较。[E1,E2,E8]

表 1. 实验身份与评价对象。

实验	评价对象与范围	角色	可回答的问题
V 四格配对	π_0 与 R5；32 次名义重复＋3×256 条件	DEV_CONFIRM	完整任务上新增与旧损失是否并存
D1 教师对照	16 TRAIN＋7 SOLVER_DEV 稳定失败根；G16＋源、Noise16＋源	TRAIN／SOLVER_DEV	同状态有限搜索能否提供相对源策略的恢复见证
BC 与 keep 消融	8 个示范根、7 个 solver 根、64 完整任务条件	TRAIN／SOLVER_DEV／DEV	示范吸收、开发迁移与保持性
自身访问诊断	8 祖先×3 时点，共 24 查询	TRAIN	老师是否能挽救学生实际访问状态
自身访问示范学习	固定 keep，新增 4 条指导；最多 1000BC	TRAIN／DEV	新增指导能否改善独立学生闭环
双引擎回放	同一 01966080 模型在 MJX 与 PhysX 各 1 固定初态	固定 DEV	该指定模型能否在两引擎满足共同声明的 1 s 无最低前向速度稳定着陆要求

完整 DEV 四格分别为 A 名义无扰动、B 随机初态无扰动、C 名义初态加请求扰动、D 随机初态加相同请求扰动。C／D 包含四个起扰时点 0、5、10、15，每次三控制步脉冲，四通道请求范围为声明的±0.25。配对比较区分共同请求与实际作用；提前失败样本保留。V 的 A 格为同一名义初态的 32 次重复；BC 完整 DEV 的 A 格为同一名义初态的 16 个数值拷贝，均不代表不同物理初态。[E1,E3—E7]

D1 先采集 128 个 TRAIN 和 32 个 SOLVER_DEV 祖先，再根据独立源策略失败情况选择教师评价根。16 个 TRAIN 和 7 个 solver 根在选教师前已经固定，不能反过来按 G 是否成功筛题。D1 仍是经过失败筛选的条件分布，其教师成功数不能解释为完整任务总体成功率。[E2]

5.2 对照、选模与复核

G 与有色噪声教师使用相同快照、相同候选数、同一冻结尾部和完整 17 世界布局，固定赢家后各复核两次。这是候选数和评价结构匹配，并不自动包含相同的生成器预训练成本。要证明整体计算或样本效率优势，还需计入探索、G 训练、示范收集、学生更新和所有评价费用。

有限 BC 试验按固定 7 个 solver 开发根的独立学生成功数选择候选，平局取最早更新。若完整 DEV 的 B 或 D 格相对 π_0 下降超过 5 个百分点，则执行一次预声明的源策略／候选配对复核；确认退化后排除该节点并停止试验。候选还在全部 8 个 TRAIN 根上做两次固定复核。通过格总数警戒不表示逐题旧损失为零。

5.3 指标、成本与统计约束

主指标为独立学生任务成功、式(2)的新增／旧损失／净差、教师可解而学生失败的数量，以及固定复核的稳定成功／稳定失败／歧义。回报、动作拟合误差和梯度关系用于解释学习过程，不替代成功判据。计费单位为实际批次的环境控制步（charged），每步 20 ms，不是 5 ms 积分子步数。终止前活跃控制步（active）与终止后填充步（padding）分别列出；active 不等于成功或可学习样本。BC、PPO、E 和 G 更新数分别记录，不将监督更新数当环境步数。

【待补 P1】正式统计需以独立训练种子为主要重复单位，采用共同条件的配对评价，并报告逐种子结果、均值与不确定性。当前单条训练谱系与同祖先重复不提供多种子显著性结论。最终评价分布、模型选择与统计规则应在开启 TEST 前冻结。

6 已有实验证据与待补结果

6.1 完整任务中的新增能力与旧能力损失

表 2. V 四格配对结果：π_0 与冻结历史候选 R5。[E1]

条件	分母	π_0 成功	R5 成功	R5 新增 G	R5 旧损失 L
A 名义／无扰动	32 次同初态重复	27	32	5	0
B 随机／无扰动	256	189	231	55	13
C 名义／有扰动	256	187	245	68	10
D 随机／有扰动	256	167	210	69	26

在 B／C／D 合计 768 个配对条件中，R5 新增 192 例、丢失 49 例，净增加 143 例。该结果说明一个已有候选可以同时具有新成功与旧能力损失，为本文同时报告 G 和 L 提供直接依据。它不是对 G、E 或反馈单

个模块的因果消融，也不能据总成功提高宣称无遗忘。V 计费 800,000 个环境控制步，其中 active 为 136,198、padding 为 663,802；该费用独立于下述 D2 预算，不并入一个看似统一的“训练步数”。

6.2 生成教师与噪声教师的有限同状态对照

表 3. D1 教师互补矩阵。[E2]

数据角色	仅 G 合格	仅 Noise 合格	两者合格	两者均未合格	歧义	全部根数
TRAIN	3	5	5	2	1	16
SOLVER_DEV	1	1	2	3	0	7

生成教师在 TRAIN 上提供 8 条合格增量教案，在 SOLVER_DEV 上提供 3 个稳定见证；Noise 分别有 10 个和 3 个非歧义成功根。TRAIN 根 80 因 G 分支的源策略标签翻转，按联合配对规则单列歧义；Noise 自身的源分支为 0/0/0、固定赢家为 1/1/1。因此，Noise 按自身资格有 11/16 合格根，而排除联合歧义后的表 3 为 10 个；不能将联合隔离写成 Noise 该根不可靠。表中“合格”指固定赢家达到重复验证资格。TRAIN 根 26 的 Noise 首搜无成功赢家，但第二次复核中候选 11 出现成功；它未满足冻结赢家资格。因此，G-only 不能解读为 Noise 从未找到任何成功，更不能解读为该状态 Noise 不可解。G-only 和 Noise-only 同时存在，支持该资格协议下的有限同根互补性；这组结果不支持 G 总体成功率高于 Noise。

8 条 G 教案覆盖四个起扰时点，共 525 帧真实观测—动作样本。按首次同快照 R5 接续标签，其中 5 个根被救回、3 个根失败；后者不等于三次稳定失败，例如根 10 在后续复核曾成功。它们相对 π_0 是增量指导，但不能全部声称为相对所有历史策略的新技能。D1 总计费 180,909，包含保留的失败尝试预留 6,800；工程错误不计作无解。[E2]

6.3 教师指导吸收、keep 覆盖与权重干预

表 4. 已完成 BC 开发试验。不同更新数的行用于记录试验结果，不构成严格等更新因果比较。[E3—E5]

试验	最大实际更新／阶段候选	候选稳定 TRAIN 吸收	候选 solver 成功	所报节点旧损失首次／复核	结论
原 BC＋keep	2000／1000	4/8	3/7	7／3	部分吸收与迁移；仍有保持债务
增加 keep 覆盖	2000／1000	4/8	3/7	5／4	首次与复核方向不同，可靠保持改善未建立
keep/demo=1.5/0.5	100／0	以原 π_0 为阶段候选	以原 π_0 为阶段候选	BC100 首次 6／复核 7	BC100 的 B 格退化经复核确认，按规则停止

覆盖干预在固定 8 条教案下扩大旧技能 TRAIN 数据，仍未形成可靠保持改进。权重干预固定数据与每组 batch，从原 π_0 重新开始；BC100 时 TRAIN 为 2/8、solver 为 2/7，虽然部分指标较同更新控制变化，B 格退化触发原停止规则，不能只挑总损失下降的部分作为成功结论。

对旧技能保持与示范损失的同批梯度分析显示两者常出现负余弦，这提供了优化冲突的诊断线索，但不构成容量不足或遗忘机制的因果证明。模型参数更多、训练更久或增加损失项均不是由这些结果自动导出的结论。

6.4 学生自身访问状态：可用指导与学生学习

在固定 BC1000 学生的 8 个 TRAIN 祖先上，24 个预声明查询全部完成。12 个查询属于 G 增量见证，6 个可以由 π_0 稳定接续，4 个在本预算内未找到解，另有 1 个源分支歧义和 1 个固定赢家歧义。全部有效、失败与歧义条件均保留。[E6]

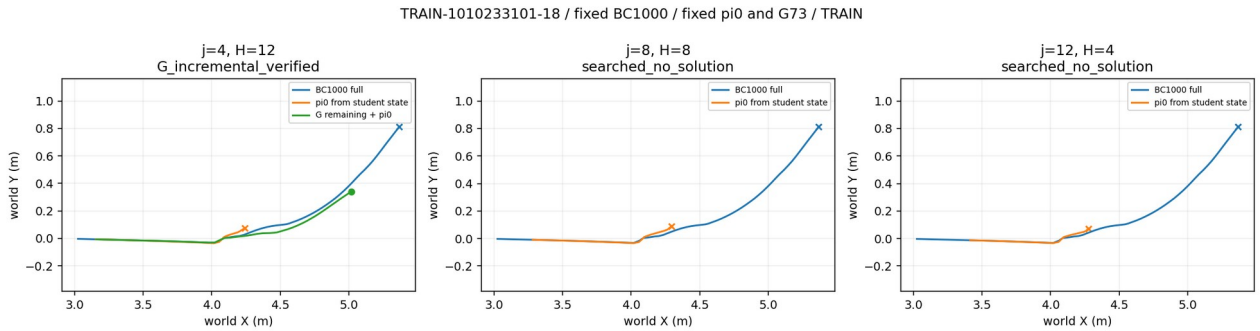


图 2. TRAIN 根 18 的三个预声明查询。 蓝线为固定学生的完整接续，橙线为学生状态交回 π_0，绿线为剩余 G 桥接后交回 π_0；轨迹在真实终点截止。j=4 有稳定增量见证，j=8 和 j=12 在固定预算内未找到解。此图展示同一根的正负结果，不能将绿色教师轨迹算作独立学生成功。全部 8 根与 24 条件见[E6]。

历史 BC1000 稳定失败祖先为 18、30 和 55；根 63 的三次标签为 1/1/0，属于歧义。真正满足本次新增示范条件的查询只有 18@j4、30@j4、55@j8、55@j12，共 4 条、3 个祖先、228 帧。其余 G 成功包括原学生已能完成的祖先，不能用来解释稳定失败根的改善。诊断新增计费 97,801，其中活跃控制步 71,025、填充 26,776，未做学生或教师更新。[E6]

随后仅改变 TRAIN 示范支持，从原 π_0 重新训练 1000 次 BC，并完成全部预声明节点和候选固定复核。原 keep、网络、优化器超参数及成功门槛均保持。表 5 对照同更新数的 keep 覆盖控制组，避免将旧 2000 次运行末点与新 1000 次运行直接比较。[E4,E7]

表 5. 自身访问示范干预的同更新对照。每格为“控制／新示范”；均为节点首次评测。

BC 更新	TRAIN（/8）	solver（/7）	完整 DEV（/64）	新增 G	旧损失 L
0	0／0	0／0	38／38	0／0	0／0
100	3／3	1／0	51／51	21／21	8／8
500	3／4	2／2	54／54	20／20	4／4
1000	5／5	3／3	55／56	22／20	5／2

两个试验按同一 7 根 solver 规则均选择 BC1000。新示范学生在完整 DEV 的 A／B／C／D 格分别为 16／13／15／12，各格 16 个条件，合计 56/64；原 π_0 为 38/64。首次配对得到新增 20、旧损失 2、净增 18；控制为新增 22、旧损失 5、净增 17。这是有限开发条件上的首次结果。新阶段没有触发 B／D 格总数警戒，因此未执行额外完整 DEV 配对复核；相应重复保持性应记“未运行”，不能用 2 例旧损失宣布稳定保持改善。

全部 8 个 TRAIN 根的首次加两次固定复核显示，新旧学生稳定成功均为 4/8。新学生稳定成功根为 37、10、26、30，稳定失败根为 68、18、63；root55 标签为 1/0/0，属于歧义。与控制相比，root30 由稳定失败变为稳定成功，但 root68 由稳定成功变为稳定失败；root55 有指导后仍未稳定吸收。这里 root68 是历史学生曾学得的新技能丢失，不能混为 π_0 旧成功损失。solver 保持 3/7，包括全部 3 个 G 已解根及 4 个 G 未取得资格根，不能只报 3/3。

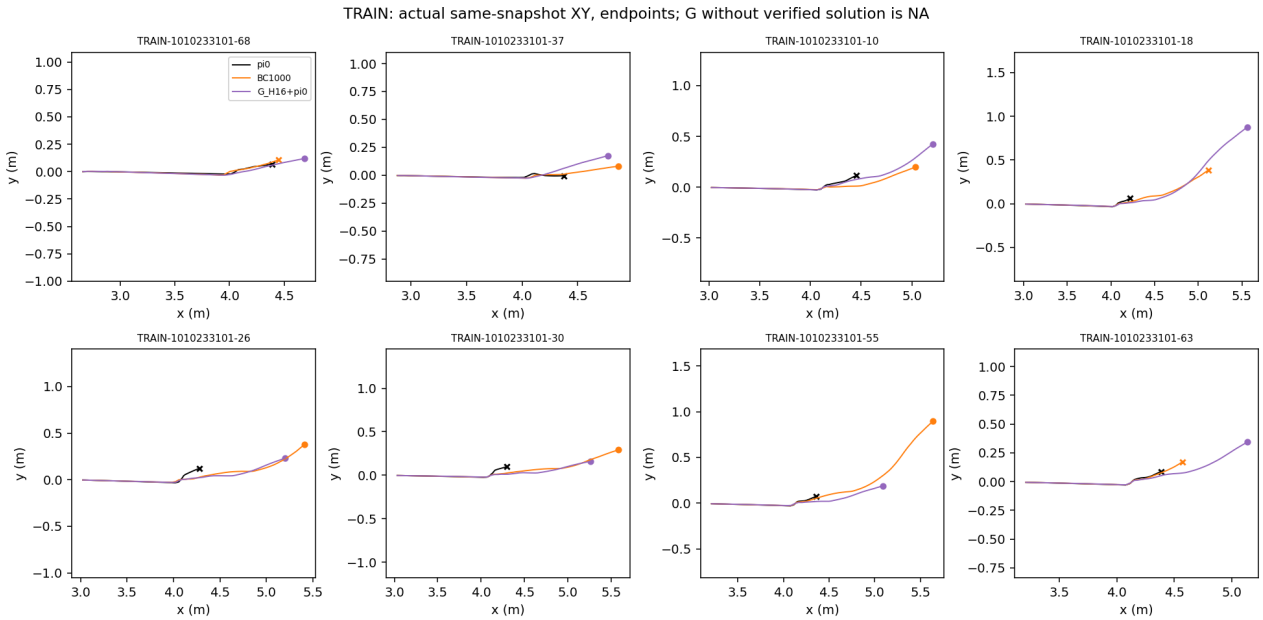


图 3. BC1000 新示范学生的全部 8 个 TRAIN 根。 保留 π_0、G 教师及独立学生的实际 XY 轨迹，按真实终点截止。学生曲线采用本阶段 BC1000 首次评测；π_0 与原 D1 的 H16+π_0 老师轨迹按身份锁复用，教师曲线取原第二次复核。稳定学生标签依据另两次固定复核，不能从单条轨迹认定稳定成功。根 55 的首次阳性与两次复测失败均在证据表中保留。[E7]

本阶段新增计费 147,537，其中活跃控制步 72,892、填充 74,645，耗时 1,262.972 s；完成 1000/1000 次监督更新，PPO／E／G 更新均为 0。D2 累计 1,122,852/2,000,000，V 与 D1 前置费用另列；未使用的预算不自动转为下一轮训练。该试验支持“特定根可修复，同时伴随其他根回退”的开发观察，尚未建立稳定吸收总数或可靠保持性净提升。原 π_0 与 R5 保留，没有发布新策略。

6.5 双引擎可执行性与迁移证据边界

已有 sim2sim 展示使用同一 transition_01966080 模型，在 MJX-Warp 与 Isaac／PhysX 中各完成一个固定开发初态回放。该模型来自另一条 transition_9904128 父源，并经过 1,966,080 次 PhysX PPO 新增交互；不是本稿 retention 的 transition_4988928 源 π_0。[E8]

两个引擎使用同一评分器：确认起跳与落地后，合法轮接触及平台支撑持续满足，|roll|<10°、|pitch|<15°、机体 x／y 角速度绝对值各<1 rad/s、世界侧向速度绝对值<0.25 m/s，连续至少 1 s；不设最低前向速度。平台边界、支撑阈值和起落确认条件也随评分器冻结。角速度不是欧拉角导数。表中接触数据无效步为 0 仅表明输入有效性检查通过，不能解释为每步均稳定或全程没有接触违规。

表 6. 指定 sim2sim 模型的双引擎固定 DEV 回放。[E8]

引擎	固定物理初态数	首次满足严格稳定落地时刻	最长连续稳定时长	接触数据无效控制步	结果
MJX-Warp	1	2.68 s	1.10 s	0	满足该回放的 1 s 稳定落地要求
Isaac／PhysX	1	2.80 s	5.68 s	0	满足该回放的 1 s 稳定落地要求

两个引擎的 Actor 与 normalizer 使用同一导出文件，且现存原始输入离线重评分与保存结果一致。这支持指定模型的双引擎可执行性；目前不支持零样本 MuJoCo→PhysX 迁移或大范围泛化。该回放从 x=1.5 m 开始，采用无最低前向速度的 1 s 稳定窗口；retention 从 x=2.5 m 开始，要求前速≥0.5 m/s 及 25 步稳定。

两者还有角速度、侧向速度及平台接触判据差异，不能仅以窗口时长换算。不能将两个口径的成功数合并，更不能将该模型写成当前 JIT 最终学生的迁移结果。

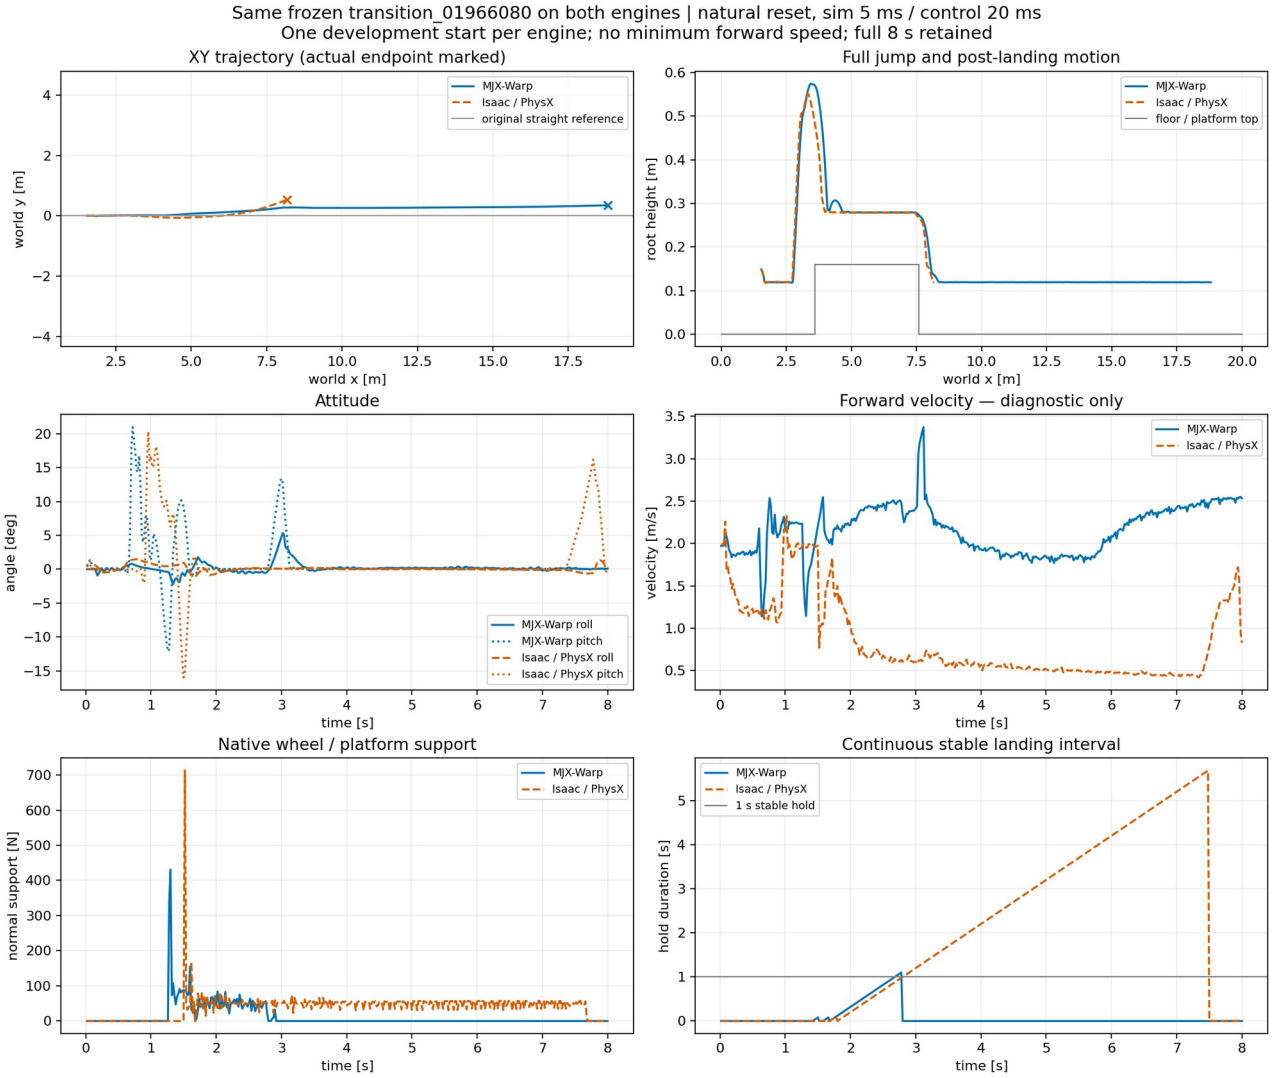


图 4. 既有独立 sim2sim 模型的双引擎回放。 同一 Actor／normalizer，在每引擎一个固定开发初态执行 8 s。左上为等比例世界 XY 实际轨迹，其余面板保留跳跃高度、姿态、速度、接触与连续稳定时长。两引擎接触／执行器经过各自标定，图中轨迹差异保留；该图属于工程可执行性证据，不是当前 JIT 学生的迁移结论。[E8]

6.6 正式主实验表：保留待补位置

表 7. 最终论文主比较表（尚未填数，不以当前开发结果冒充）。

方法	独立训练种子	未见完整任务成功率	旧能力保持率	新增成功／旧损失	统一总成本
冻结 π_0	【待补 P1】	—	—	—	—
等预算继续 PPO	【待补 P1】	—	—	—	—
随机探索＋相同学习器	【待补 P2】	—	—	—	—
学习探索＋Noise 教师＋相同学习器	【待补 P3】	—	—	—	—
完整 JIT：E＋G＋π＋反馈	【待补 P1—P4】	—	—	—	—

【待补 P1：最终学生净收益】这里放同一源策略、统一成功标准和完整自然起点下的独立训练种子结果。建议至少 3 个独立训练种子作初步统计，并依观察到的方差确定更多重复；不能将 3 次固定复核替代训练种子。应给出逐种子成功率、新增与旧损失，以及与等预算继续 PPO 的配对比较。该建议不表示已授权或已经执行这些训练。

【待补 P2：可学习探索的作用】这里放固定后续教师／学生、学习 E 与随机探索等总预算的对照。图应同时显示真实状态覆盖、可验证恢复指导产出和最终学生收益随成本变化，防止以轨迹宽度或新颖性奖励替代可学习性。

【待补 P3：生成教师的价值】这里放 G 与 Noise 或更简单教师在相同源策略、快照、候选预算、动作范围和尾部条件下的比较，并计入 G 训练成本；同时训练各自示范对应的独立学生。需要教师成功／独有见证、教案覆盖、学生吸收和总成本四组结果，不只放 G 的去噪 MSE。

【待补 P4：学习进展反馈的作用】这里放开／关反馈的同预算多轮对照，记录每轮实际探索奖励、合格教案、策略新增／丢失及固定独立评价。应固定学生继承与候选处理规则，不能用“连续运行了很多轮”代替学习进展有效性。

【待补 P5：未见扰动与同身份 sim2sim】这里放冻结最终 JIT 学生后，对未见控制扰动、外力扰动及初态的完整评价，并在两个引擎中使用同一 Actor／normalizer 和统一终点。若目标引擎进行了训练或物理标定，需分别报告适配预算和条件；当前已有双引擎示例不填入这一空表。

【待补 P6：真实平台验证】若拟投稿定位要求实机结果，这里放安全审批后同身份策略的实际跳跃与扰动恢复、重复次数、失败情况及部署频率；目前留空，不将仿真视频作为实机证据。

7 讨论与局限

恢复见证的价值及其边界。 当前证据表明，一些源策略失败状态存在可以重复验证的短动作桥接。它们能为学习器提供任务相关指导，而非仅增加无标签失败轨迹。但有限候选中的成功见证不证明扩散必要性，未找到见证也不证明动力学上无解。D1 的 G 与 Noise 互补结果，应成为后续等成本对照的依据。

从老师到学生仍是核心瓶颈。 学生不仅要拟合老师轨迹上的动作，还要在自己的状态分布中保持闭环正确性。自身访问诊断确认了部分失败状态上的可用指导，新增指导后 root30 被稳定修复，但伴随 root68 稳定丢失，稳定吸收总数仍为 4/8；因此当前结果未建立稳定总收益。即使局部动作误差下降，也不能推导稳定性保证；仅增加 keep 覆盖或改变权重已经出现有限负结果，应完整保留。

数值重复与统计独立性。 快照包含控制历史和事件上下文，但并非物理引擎内部状态的完全镜像。批次布局、接触重建和数值误差可改变终点标签，故本文保留固定布局复核与歧义分类。同根多个时间点并不独立，发展过程中反复使用的开发集不能称未见测试集。

方法版本与证据不能混用。 历史连续主线、近期 retention 诊断和独立 sim2sim 线有不同的策略身份、重置语义或成功口径。它们可分别支持实现、诊断和可执行性，不能拼成同一最终策略的完整优势链。正式结论应以冻结方法下的统一评价为准。

8 结论

本文提出并实现了围绕可学习探索、生成式恢复教师和跳跃策略学习的 JIT 框架，以真实扰动后状态、短动作桥接和成功接续构建可追溯恢复示范，并将学生新增能力、旧能力损失和教师辅助成功分别计量。已有开发实验提供了生成教师的有限恢复见证、与噪声教师的互补性，以及老师到学生转化问题的可检验诊断。当前证据尚不足以支持完整 JIT 相对简单方法的稳定优势、可靠无遗忘或最终策略泛化提升。后续应优先补齐等总成本、多独立训练种子和同身份完整任务评价，再据此确定投稿结论的强度。

参考文献

[1] Fahmi S, Ilvonen A, Zapolsky S, et al. Bicycle Acrobatics with Reinforcement Learning. arXiv:2608.00880, 2026. 原始论文。

[2] Rho S, Fahmi S, Kim J, Ilvonen A, Ha S, Nelson G. LineRides: Line-Guided Reinforcement Learning for Bicycle Robot Stunts. arXiv:2605.05110, 2026. 原始论文。

[3] Johannink T, Bahl S, Nair A, et al. Residual Reinforcement Learning for Robot Control. arXiv:1812.03201, 2018. 原始论文。

[4] Schulman J, Wolski F, Dhariwal P, Radford A, Klimov O. Proximal Policy Optimization Algorithms. arXiv:1707.06347, 2017. 原始论文。

[5] Burda Y, Edwards H, Storkey A, Klimov O. Exploration by Random Network Distillation. arXiv:1810.12894, 2018. 原始论文。

[6] Florensa C, Held D, Wulfmeier M, Zhang M, Abbeel P. Reverse Curriculum Generation for Reinforcement Learning. CoRL, 2017. 原始论文。

[7] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models. arXiv:2006.11239, 2020. 原始论文。

[8] Chi C, Feng S, Du Y, et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. Robotics: Science and Systems, 2023. 作者项目与论文。

[9] Ross S, Gordon G, Bagnell D. A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning. AISTATS, PMLR 15:627–635, 2011. 原始论文。

附录 A 证据索引与复核说明

本稿表格以以下本地工件为依据。原始模型、全部逐步轨迹与完整日志保留在服务器；文稿与紧凑报告不是可独立重跑全部实验的数据包。参考文献在 2026 年 10 月 11 日通过论文原始记录／作者页面核对。

编号	原始／紧凑证据入口	本稿用途
E1	V 配对汇总	表 2、完整任务新增／旧损失
E2	D1 汇总；逐根标签与费用	表 3、教师互补与教案准入
E3	原 BC 结果	表 4、老师一学生转化
E4	keep 覆盖结果	表 4、同更新学习控制
E5	权重干预结果	表 4、保持性早停
E6	自身访问完整 24 条件与 8 张 XY	图 2、教师指导诊断
E7	自身访问示范学习结果	表 5 与新增示范实测结果
E8	Sim2Sim 身份与原始输入审计	表 6、策略身份与口径边界
E9	方法代码与框图对齐记录	第 4 节网络、时序与反馈实现

附表 A1. D1 计费分解，单位为环境控制步。

范围	charged	active	padding
G 完成搜索与两次固定复核	72,862	55,235	17,627
Noise 完成搜索与两次固定复核	78,472	48,340	30,132
共享采集、π_0 筛选与 R5 对照	22,775	14,167	8,608
G 显存不足失败预留	6,800	UNKNOWN	UNKNOWN
D1 合计	180,909	已知 117,742	已知 56,367

G 完成批的填充较少，但活跃控制步较多；加上归属 G 的失败预留后，G 线 charged 为 79,662，高于 Noise 的 78,472。该比较仍未含历史 E／G 训练费，不支持端到端成本优势。失败预留的 active／padding 未知，不能删去或分摊为已知值。

自身访问诊断的历史执行版本为 90a3ddc；旧 capture 行中的 coordinates／phase／cell 继承祖先，仅作元数据，真实 query 状态以 snapshot／trace 为准。本轮示范学习执行版本为 0f4ed45，最终 BC1000 文件 SHA-256 为 542d26e4df61aa45083c1116f9ba1165f20e4dcdbbe7cd8e703d385dc3613d8a；后续文稿提交不回写其执行身份。

作者提供框图原件随文保存为 generative_bridge_assets/JIT-core-method-network-icons.pdf；其 SHA-256 及渲染来源见 framework_provenance.json。图 1 只是原 PDF 的页面渲染，不重新绘制或替换其内容。

当前关键运行根为/home/qy/DVGC/JIT/runs/experiments/retention_next_20261010/。近期 BC、自身访问诊断及本文写作没有继续 R73／R74 训练谱系，没有打开最终 TEST，也没有新策略发布记录。论文叙述遵循实际模型身份和已完成节点，不把文稿中的后续设计视为已经执行。

附录 B 待补证据清单

编号	放在论文哪里	需要补的核心结果	目前状态
P1	摘要、表 7、结论	最终独立学生对等预算 PPO 的多训练种子成功／新增／旧损失	空缺；已有单谱系开发证据不能替代
P2	探索模块消融图	学习 E 与随机探索的可用指导产出及最终学生等成本曲线	空缺；有实现和局部运行，不等于收益证据
P3	教师比较表、学生比较表	G 与 Noise／简单教师的完整成本和学生转化对照	D1 互补矩阵已填；优势与学生对照空缺
P4	迭代曲线、反馈消融	有／无学习进展反馈的多轮同预算独立评价	接线与运行证据不替代因果消融
P5	泛化与 sim2sim 图表	同一最终 JIT 学生、统一终点、未见扰动与跨引擎重复	现有另一模型双引擎固定 DEV 已填；主张所需证据空缺
P6	实机实验	真实平台重复跳跃／扰动恢复及失败统计	未验证；是否为投稿必要项取决于定位

补齐这些表格前，建议保留本稿当前有限证据表述。若最终对照仍不支持完整框架优势，应调整论文主张和投稿定位，而不是删去负结果或放宽成功判据。